Tidyverse - Exercices (Correction)

Pierre Lafaye De Micheaux

Novembre 2023

Iris

Nous considérons le jeu de données iris. Répondre aux questions suivantes en utilisant les fonctions du package dplyr :

1. Sélectionner les variables Petal. Width et Species.

```
iris %>%
  select(Petal.Width, Species) %>%
  head(3)

## Petal.Width Species
## 1     0.2  setosa
## 2     0.2  setosa
## 3     0.2  setosa
```

2. Construire une table qui contient uniquement les iris d'espèce versicolor ou virginica.

```
# Avec l'opérateur %in%
iris %>%
  filter(Species %in% c("versicolor", "virginica")) %>%
 head(3)
     Sepal.Length Sepal.Width Petal.Length Petal.Width
##
                                                            Species
## 1
              7.0
                           3.2
                                        4.7
                                                    1.4 versicolor
              6.4
                          3.2
## 2
                                        4.5
                                                    1.5 versicolor
## 3
              6.9
                           3.1
                                        4.9
                                                    1.5 versicolor
# Avec l'opérateur logique OR
iris %>%
  filter(Species == "versicolor" | Species == "virginica") %>%
 head(3)
```

```
##
     Sepal.Length Sepal.Width Petal.Length Petal.Width
                                                             Species
## 1
              7.0
                           3.2
                                         4.7
                                                      1.4 versicolor
## 2
              6.4
                           3.2
                                         4.5
                                                      1.5 versicolor
                           3.1
## 3
              6.9
                                         4.9
                                                      1.5 versicolor
```

3. Calculer the nombre d'iris setosa en utilisant summarise.

```
iris %>%
  filter(Species == "setosa") %>%
  summarise(n = n())
##
      n
## 1 50
# avec group_by()
iris %>%
  group_by(Species) %>%
 summarise(n = n())
## # A tibble: 3 x 2
##
     Species
##
     <fct>
                 <int>
## 1 setosa
                    50
## 2 versicolor
                    50
## 3 virginica
                    50
  4. Calculer la moyenne de la variable Petal. Width pour les iris de l'espèce versicolor.
iris %>%
  filter(Species == "versicolor") %>%
  summarise(mean_petal_width = mean(Petal.Width))
     mean_petal_width
## 1
                 1.326
  5. Ajouter dans le jeu de données la variable Sum_Petal qui correspond à la somme de Petal.Width et
     Sepal.Width.
iris %>%
  mutate(Sum_Petal = Petal.Width + Sepal.Width) %>%
  head(3)
     Sepal.Length Sepal.Width Petal.Length Petal.Width Species Sum_Petal
## 1
              5.1
                           3.5
                                         1.4
                                                     0.2 setosa
## 2
                           3.0
              4.9
                                         1.4
                                                     0.2 setosa
                                                                         3.2
## 3
              4.7
                           3.2
                                         1.3
                                                     0.2 setosa
                                                                         3.4
  6. Calculer la moyenne et la variance de la variable Sepal.Length pour chaque espèce.
iris %>%
  group_by(Species) %>%
  summarise(mean_sepal_length = mean(Sepal.Length),
            var_sepal_length = var(Sepal.Length))
## # A tibble: 3 x 3
##
     Species
              mean_sepal_length var_sepal_length
##
     <fct>
                             <dbl>
```

0.124

0.266

5.01

5.94

6.59

1 setosa

2 versicolor

3 virginica

Aviation

Nous considérons la table hflights qui contient des informations sur les vols au départ des aéroports Houston George Bush Intercontinental Airport (IATA: IAH) et William P. Hobby Airport (IATA: HOU),

```
library("hflights")
hflights <- as_tibble(hflights)</pre>
```

1. Sélectionner les variables qui se situent entre Origin et Cancelled de différentes façons.

```
# Visualiser le jeu de données
View(hflights)
# Remarque : positions de Origin et Cancelled
names(hflights)[c(14, 19)]
## [1] "Origin"
                   "Cancelled"
# Remarque : quelles sont les variables entre ces deux-là ?
names(hflights)[15:18]
## [1] "Dest"
                  "Distance" "TaxiIn"
                                        "TaxiOut"
# On les sélectionne par le nom
hflights %>%
  select(Dest, Distance, TaxiIn, TaxiOut) %>%
 head(3)
## # A tibble: 3 x 4
    Dest Distance TaxiIn TaxiOut
##
             <int> <int>
     <chr>
                            <int>
## 1 DFW
                224
                         7
                                13
## 2 DFW
                224
                                 9
                         6
## 3 DFW
                224
                         5
                                17
# par la position (argument vectoriel)
hflights %>%
  select(names(hflights)[15:18]) %>%
 head(3)
## # A tibble: 3 x 4
    Dest Distance TaxiIn TaxiOut
##
              <int> <int>
     <chr>
                             <int>
## 1 DFW
                224
                         7
                                13
## 2 DFW
                224
                         6
                                 9
## 3 DFW
                224
                         5
                                17
# par des helpers
hflights %>%
  select(matches("D?st.*") | starts_with("Taxi")) %>%
 head(3)
```

```
## # A tibble: 3 x 4
##
     Dest Distance TaxiIn TaxiOut
##
     <chr>>
              <int> <int>
## 1 DFW
                          7
                                 13
                224
## 2 DFW
                224
                          6
                                  9
## 3 DFW
                224
                          5
                                 17
# par la position (argument vectoriel) en utilisant la fonction d'extraction
hflights %>%
  "["(., i = , j = 15:18) \%
  head(3)
## # A tibble: 3 x 4
     Dest Distance TaxiIn TaxiOut
##
     <chr>>
              <int> <int>
                              <int>
## 1 DFW
                          7
                                 13
                224
## 2 DFW
                224
                          6
                                  9
## 3 DFW
                224
                          5
                                 17
```

2. Sélectionner les variables DepTime, ArrTime, ActualElapsedTime, AirTime, ArrDelay et DepDelay.

```
hflights %>%
  select(ends_with(c("Time", "Delay"))) %>%
  head(3)
## # A tibble: 3 x 6
     DepTime ArrTime ActualElapsedTime AirTime ArrDelay DepDelay
       <int>
                <int>
                                   <int>
                                           <int>
                                                     <int>
                                                              <int>
## 1
        1400
                 1500
                                      60
                                              40
                                                       -10
                                                                  0
## 2
        1401
                 1501
                                      60
                                              45
                                                        -9
                                                                  1
## 3
        1352
                 1502
                                      70
                                              48
                                                        -8
                                                                  -8
```

3. Ajouter une variable ActualGroundTime qui correspond à ActualElapsedTime moins AirTime, et ne conserver que ces trois variables.

```
hflights %>%
  mutate(ActualGroundTime = ActualElapsedTime - AirTime) %>%
  select(ActualElapsedTime, AirTime, ActualGroundTime) %>%
  head(3)

## # A tibble: 3 x 3
## ActualElapsedTime AirTime ActualGroundTime
## <int> <int> <int>
```

1

2

3

60

60

70

40

45

4. Ajouter une variable AverageSpeed qui donne la vitesse moyenne du vol, ne conserver que les variables Origin, Dest, Distance, AirTime et AverageSpeed, puis ordonner la table selon les valeurs décroissantes de cette variable.

20

15

22

```
hflights %>%
  mutate(AverageSpeed = Distance / AirTime) %>%
  select(Origin, Dest, Distance, AirTime, AverageSpeed) %>%
  arrange(desc(AverageSpeed)) %>%
  head(3)
## # A tibble: 3 x 5
     Origin Dest Distance AirTime AverageSpeed
##
     <chr> <chr>
##
                      <int>
                               <int>
                                             <dbl>
## 1 IAH
                                              12.7
            AUS
                        140
                                  11
## 2 IAH
            MEM
                        469
                                  42
                                              11.2
## 3 IAH
            CLT
                        913
                                  85
                                              10.7
  5. Sélectionner les vols à destination de JFK, et ne conserver que les variables FlightNum, Origin et Dest.
hflights %>%
  filter(Dest == "JFK") %>%
  select(FlightNum, Origin, Dest) %>%
  head(3)
## # A tibble: 3 x 3
     FlightNum Origin Dest
##
         <int> <chr>
                       <chr>
## 1
           620 HOU
                       JFK
## 2
           622 HOU
                       JFK
## 3
           620 HOU
                       JFK
  6. Calculer le nombre de vols à destination de JFK.
hflights %>%
  filter(Dest == "JFK") %>%
  summarise(n = n())
## # A tibble: 1 x 1
##
         n
##
     <int>
## 1
       695
  7. Créer un résumé de hflights qui contient :
       • n : le nombre total de vols ;
       • n_dest: le nombre total de destinations ;
       • n_carrier : le nombre total de compagnies.
hflights %>%
  summarise(n
                       = n(),
            n_dest
                       = n_distinct(Dest),
             n_carrier = n_distinct(UniqueCarrier))
## # A tibble: 1 x 3
##
          n n_dest n_carrier
      <int> <int>
                        <int>
## 1 227496
               116
                           15
```

- 8. Créer un résumé de hflights qui contient, pour les vols de la compagnie AA:
 - n : le nombre total de vols ;
 - n_cancelled : le nombre total de vols annulés ;
 - mean_delay : la valeur moyenne de ArrDelay (attention à la gestion des NA).

```
## # A tibble: 1 x 3
## n n_cancelled mean_delay
## <int> <int> <dbl>
## 1 3244 60 0.892
```

- 9. Calculer pour chaque compagnie:
 - n : le nombre total de vols ;
 - mean_air_time : la valeur moyenne de AirTime.

```
hflights %>%
group_by(UniqueCarrier) %>%
summarise(n = n(),
    mean_air_time = mean(AirTime, na.rm = TRUE),
    .groups = 'drop') # Évite un message d'avertissement
```

```
## # A tibble: 15 x 3
##
      UniqueCarrier
                        n mean_air_time
      <chr>
                    <int>
                                   <dbl>
##
                                    69.7
##
   1 AA
                     3244
## 2 AS
                      365
                                   254.
## 3 B6
                      695
                                   184.
## 4 CO
                    70032
                                   145.
## 5 DL
                     2641
                                    97.8
## 6 EV
                     2204
                                   104.
## 7 F9
                      838
                                   125.
## 8 FL
                     2139
                                    92.7
## 9 MQ
                     4648
                                    93.8
                    16061
## 10 00
                                   113.
## 11 UA
                     2072
                                   157.
## 12 US
                     4082
                                   134.
## 13 WN
                    45343
                                    86.7
## 14 XE
                    73053
                                    83.2
## 15 YV
                       79
                                   122.
```

10. Ordonner les compagnies en fonction des retards moyens au départ.

```
## # A tibble: 15 x 2
##
      UniqueCarrier mean_dep_delay
##
##
   1 YV
                               1.54
##
    2 US
                               1.62
##
   3 AS
                               3.71
##
   4 FL
                               4.72
## 5 F9
                               5.09
##
   6 AA
                               6.39
## 7 XE
                               7.71
## 8 00
                               8.89
## 9 CO
                               9.26
## 10 DL
                               9.37
## 11 MQ
                              11.1
## 12 EV
                              12.5
## 13 UA
                              12.9
## 14 B6
                              13.3
## 15 WN
                              13.5
```

Tennis

Nous considérons les données sur les résultats de tennis dans les tournois du Grand Chelem en 2013. Les données, ainsi que le descriptif des variables, se trouvent à l'adresse suivante :

https://archive.ics.uci.edu/ml/datasets/Tennis+Major+Tournament+Match+Statistics

Nous considérons d'abord le tounoi masculin de Roland Garros. Utiliser les verbes de dplyr pour répondre aux questions suivantes.

1. Importer les données.

```
fpath <- file.path("data", "Tennis", "FrenchOpen-men-2013.csv")</pre>
rg_tbl <- readr::read_csv(fpath)</pre>
## Rows: 125 Columns: 42
## -- Column specification -----
## Delimiter: ","
## chr (2): Player1, Player2
## dbl (40): Round, Result, FNL.1, FNL.2, FSP.1, FSW.1, SSP.1, SSW.1, ACE.1, DB...
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.
rg_tbl %>% pillar::glimpse() # un peu comme str()
## Rows: 125
## Columns: 42
## $ Player1 <chr> "Pablo Carreno-Busta", "Somdev Devvarman", "Tobias Kamke", "Ju~
## $ Player2 <chr> "Roger Federer", "Daniel Munoz-De La Nava", "Paolo Lorenzi", "~
## $ Round
          ## $ Result <dbl> 0, 1, 1, 1, 0, 1, 0, 1, 0, 0, 1, 0, 0, 1, 1, 1, 0, 0, 1, 0, 0,~
## $ FNL.1
           <dbl> 0, 3, 3, 3, 0, 3, 2, 3, 0, 0, 3, 2, 0, 3, 3, 3, 0, 2, 3, 2, 0,~
```

```
## $ FNL.2
             <dbl> 3, 0, 2, 1, 3, 1, 3, 2, 3, 3, 0, 3, 3, 0, 2, 0, 3, 3, 0, 2, 3,~
## $ FSP.1
             <dbl> 62, 62, 62, 72, 52, 70, 63, 59, 56, 63, 48, 78, 66, 83, 69, 50~
             <dbl> 27, 54, 53, 87, 31, 58, 71, 42, 27, 62, 29, 85, 48, 51, 84, 32~
## $ FSW.1
## $ SSP.1
             <dbl> 38, 38, 38, 28, 48, 30, 37, 41, 44, 37, 52, 22, 34, 17, 31, 50~
## $ SSW.1
             <dbl> 11, 22, 15, 19, 22, 18, 38, 25, 13, 29, 20, 22, 13, 6, 29, 23,~
## $ ACE.1
             <dbl> 1, 7, 4, 14, 4, 4, 5, 7, 0, 5, 12, 2, 7, 6, 11, 5, 1, 5, 7, 7,~
## $ DBF.1
             <dbl> 3, 3, 6, 2, 4, 4, 5, 2, 6, 4, 4, 1, 5, 0, 4, 0, 5, 7, 2, 3, 4,~
             <dbl> 12, 26, 42, 48, 21, 35, 45, 41, 12, 41, 33, 24, 24, 27, 57, 29~
## $ WNR.1
## $ UFE.1
             <dbl> 29, 20, 55, 27, 24, 36, 80, 49, 28, 44, 12, 30, 24, 18, 42, 33~
## $ BPC.1
             <dbl> 1, 5, 10, 4, 1, 6, 5, 10, 1, 1, 7, 5, 1, 5, 6, 6, 5, 4, 7, 5, ~
## $ BPW.1
             <dbl> 3, 8, 22, 13, 1, 12, 12, 14, 2, 6, 11, 17, 5, 14, 7, 10, 8, 5,~
             <dbl> 9, 12, 14, 14, 3, 8, 28, 11, 11, 19, 14, 12, 11, 5, 8, 13, 15,~
## $ NPA.1
## $ NPW.1
             <dbl> 20, 21, 32, 30, 5, 10, 41, 18, 18, 27, 21, 18, 14, 6, 13, 17, ~
             <dbl> 50, 120, 140, 163, 72, 130, 160, 136, 54, 132, 91, 174, 85, 10~
## $ TPW.1
## $ ST1.1
             <dbl> 2, 6, 6, 7, 3, 6, 3, 3, 1, 6, 6, 6, 4, 6, 6, 6, 4, 4, 6, 5, 3,~
             <dbl> 2, 6, 6, 6, 4, 5, 6, 1, 2, 6, 6, 6, 2, 6, 4, 6, 3, 6, 6, 6, 5,~
## $ ST2.1
## $ ST3.1
             <dbl> 3, 7, 3, 5, 4, 6, 3, 6, 3, 6, 6, 6, 5, 6, 7, 6, 4, 3, 6, 4, 4,~
## $ ST4.1
             <dbl> NA, NA, O, 7, NA, 6, 7, 6, NA, NA, NA, A, NA, NA, 4, NA, NA, 6~
             <dbl> NA, NA, 6, NA, NA, NA, 5, 7, NA, NA, NA, 4, NA, NA, 6, NA, NA,~
## $ ST5.1
## $ FSP.2
             <dbl> 68, 52, 46, 53, 58, 68, 59, 49, 50, 56, 47, 52, 66, 55, 54, 62~
## $ FSW.2
             <dbl> 33, 35, 42, 58, 39, 48, 67, 40, 26, 64, 22, 67, 44, 36, 58, 26~
## $ SSP.2
             <dbl> 32, 48, 54, 47, 42, 32, 41, 51, 50, 44, 53, 48, 34, 45, 46, 38~
             <dbl> 14, 24, 31, 38, 19, 17, 27, 29, 20, 35, 15, 47, 17, 18, 36, 12~
## $ SSW.2
## $ ACE.2
             <dbl> 10, 0, 6, 13, 10, 5, 5, 4, 5, 10, 3, 12, 10, 8, 7, 4, 3, 5, 3,~
## $ DBF.2
             <dbl> 0, 2, 8, 10, 1, 5, 6, 6, 1, 7, 2, 5, 6, 5, 8, 4, 4, 4, 4, 3, 4~
## $ WNR.2
             <dbl> 33, 40, 39, 72, 42, 30, 54, 44, 35, 46, 23, 72, 46, 32, 60, 15~
## $ UFE.2
             <dbl> 19, 47, 54, 56, 37, 51, 57, 72, 15, 38, 31, 64, 33, 29, 71, 35~
## $ BPC.2
             <dbl> 7, 1, 10, 4, 4, 1, 6, 9, 7, 1, 2, 5, 5, 1, 5, 1, 8, 6, 1, 4, 4~
## $ BPW.2
             <dbl> 7, 16, 18, 13, 7, 7, 20, 10, 12, 3, 2, 10, 11, 3, 15, 4, 11, 1~
## $ NPA.2
             <dbl> 14, 22, 19, 33, 12, 6, 14, 19, 13, 9, 9, 11, 10, 12, 24, 9, 6,~
## $ NPW.2
             <dbl> 18, 25, 27, 43, 13, 9, 22, 35, 21, 20, 22, 18, 16, 20, 33, 13,~
## $ TPW.2
             <dbl> 88, 106, 139, 149, 93, 93, 175, 120, 92, 130, 59, 177, 108, 75~
## $ ST1.2
             <dbl> 6, 3, 3, 6, 6, 2, 6, 6, 6, 7, 4, 4, 6, 3, 4, 2, 6, 6, 1, 7, 6,~
             <dbl> 6, 3, 3, 3, 6, 7, 2, 6, 6, 7, 2, 4, 6, 4, 6, 2, 6, 3, 3, 2, 7,~
## $ ST2.2
## $ ST3.2
             <dbl> 6, 5, 6, 7, 6, 0, 6, 4, 6, 7, 2, 7, 7, 2, 6, 3, 6, 6, 2, 6, 6,~
## $ ST4.2
             <dbl> NA, NA, 6, 6, NA, 4, 5, 1, NA, NA, NA, 6, NA, NA, 6, NA, NA, 3~
## $ ST5.2
             <dbl> NA, NA, 3, NA, NA, NA, 7, 5, NA, NA, NA, 6, NA, NA, 2, NA, NA,~
```

2. Afficher le nom des adversaires de Roger Federer.

```
rg_tbl %>%
filter(Player2 == "Roger Federer") %>% # Roger Federer n'est jamais Player1
select(Player1)
```

```
## # A tibble: 5 x 1
## Player1
## <chr>
## 1 Pablo Carreno-Busta
## 2 Somdev Devvarman
## 3 Julien Benneteau
## 4 Gilles Simon
## 5 Jo-Wilfried Tsonga
```

3. Afficher le nom des demi-finalistes.

4. Combien y a t-il eu de points disputés en moyenne par match? Il faudra penser à ajouter dans la table une variable correspondant au nombre de points de chaque match (verbe mutate).

```
rg_tbl %>%
  mutate(total_points = TPW.1 + TPW.2) %>%
  summarise(mean_total_points = mean(total_points))

## # A tibble: 1 x 1
## mean_total_points
## <dbl>
## 1 219.
```

5. Combien y a t-il eu d'aces par match en moyenne?

```
rg_tbl %>%
  mutate(aces = ACE.1 + ACE.2) %>%
  summarise(mean_aces = mean(aces))

## # A tibble: 1 x 1
## mean_aces
## <dbl>
## 1 12.7
```

6. Combien y a t-il eu d'aces par match en moyenne à chaque tour ?

```
rg_tbl %>%
mutate(aces = ACE.1 + ACE.2) %>%
group_by(Round) %>%
summarise(mean_aces = mean(aces))
```

```
## # A tibble: 7 x 2
##
     Round mean_aces
##
     <dbl>
                <dbl>
## 1
         1
                13.5
## 2
         2
                13.2
## 3
         3
                12.6
## 4
         4
                 9.12
         5
                 7
## 5
## 6
         6
                10
## 7
         7
                 6
```

7. Combien y a t-il eu de doubles fautes au total dans le tournoi?

```
rg_tbl %>%
 mutate(double_faults = DBF.1 + DBF.2) %>%
 summarise(sum_double_faults = sum(double_faults, na.rm = TRUE))
## # A tibble: 1 x 1
    sum_double_faults
##
                <dbl>
## 1
                  812
  8. Importer les données pour le tournoi de Wimbledon masculin de 2013.
fpath <- file.path("data", "Tennis", "Wimbledon-men-2013.csv")</pre>
w_tbl <- read_csv(fpath)</pre>
## Rows: 114 Columns: 42
## -- Column specification -
## Delimiter: ","
## chr (2): Player1, Player2
## dbl (38): Round, Result, FNL.1, FNL.2, FSP.1, FSW.1, SSP.1, SSW.1, ACE.1, DB...
## lgl (2): TPW.1, TPW.2
##
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.
w_tbl %>% glimpse()
## Rows: 114
## Columns: 42
## $ Player1 <chr> "B.Becker", "J.Ward", "N.Mahut", "T.Robredo", "R.Haase", "M.Gi~
## $ Player2 <chr> "A.Murray", "Y-H.Lu", "J.Hajek", "A.Bogomolov Jr.", "M.Youzhny~
## $ Round
            ## $ Result <dbl> 0, 0, 1, 1, 0, 0, 1, 0, 0, 1, 0, 1, 0, 1, 0, 1, 0, 0, 1, 0, 0,~
            <dbl> 0, 1, 3, 3, 0, 0, 3, 0, 0, 3, 1, 3, 1, 3, 0, 3, 0, 0, 3, 1, 0,~
## $ FNL.1
## $ FNL.2
            <dbl> 3, 3, 0, 0, 3, 3, 1, 3, 3, 0, 3, 0, 3, 1, 3, 0, 3, 3, 2, 3, 3,~
## $ FSP.1
            <dbl> 59, 62, 72, 77, 68, 59, 63, 61, 61, 67, 64, 78, 69, 63, 66, 68~
## $ FSW.1
            <dbl> 29, 77, 44, 40, 61, 41, 56, 47, 31, 56, 66, 46, 60, 58, 48, 54~
## $ SSP.1
            <dbl> 41, 38, 28, 23, 32, 41, 37, 39, 39, 33, 36, 22, 31, 37, 34, 32~
## $ SSW.1
            <dbl> 14, 35, 10, 12, 15, 27, 21, 21, 16, 21, 18, 9, 14, 21, 21, 15,~
## $ ACE.1
            <dbl> 5, 18, 17, 6, 7, 7, 21, 3, 4, 22, 13, 6, 3, 20, 5, 18, 3, 1, 2~
## $ DBF.1
            <dbl> 1, 4, 3, 0, 2, 6, 3, 1, 5, 6, 2, 2, 2, 7, 5, 2, 1, 3, 10, 2, 3~
## $ WNR.1
            <dbl> 26, 60, 41, 25, 32, 22, 56, 28, 20, 61, 55, 19, 33, 64, 42, 47~
## $ UFE.1
            <dbl> 18, 28, 18, 11, 29, 28, 32, 16, 18, 29, 40, 20, 33, 29, 30, 13~
## $ BPC.1
            <dbl> 5, 13, 8, 14, 2, 6, 16, 4, 1, 8, 3, 14, 7, 11, 11, 6, 0, 2, 19~
            <dbl> 1, 1, 5, 5, 0, 1, 4, 0, 1, 3, 1, 6, 2, 6, 2, 3, 0, 0, 4, 4, 0,~
## $ BPW.1
## $ NPA.1
            <dbl> 28, 27, 26, 14, 29, 11, 21, 33, 14, 47, 22, 9, 34, 25, 49, 48,~
## $ NPW.1
            <dbl> 19, 19, 17, 11, 20, 6, 15, 24, 9, 35, 15, 7, 25, 18, 29, 32, 8~
## $ TPW.1
            <dbl> 4, 7, 6, 6, 4, 3, 6, 3, 3, 7, 5, 6, 4, 6, 6, 7, 3, 4, 6, 7, 2,~
## $ ST1.1
## $ ST2.1
            <dbl> 3, 4, 6, 6, 5, 2, 6, 4, 4, 6, 4, 6, 7, 6, 4, 6, 2, 0, 4, 5, 2,~
```

```
## $ ST3.1
           <dbl> 2, 6, 6, 6, 5, 6, 3, 6, 4, 6, 7, 6, 4, 6, 5, 6, 0, 4, 7, 3, 4,~
## $ ST4.1
           <dbl> NA, 6, NA, NA, NA, NA, 6, NA, NA, NA, 2, NA, 2, 6, NA, NA, NA,~
## $ ST5.1
           <dbl> 57, 67, 70, 79, 67, 70, 73, 71, 70, 54, 67, 58, 63, 63, 65, 71~
## $ FSP.2
## $ FSW.2
           <dbl> 39, 85, 34, 35, 53, 56, 59, 55, 45, 40, 64, 33, 65, 48, 59, 46~
## $ SSP.2
           <dbl> 43, 33, 30, 21, 33, 30, 27, 29, 30, 46, 33, 42, 37, 37, 35, 29~
## $ SSW.2
           <dbl> 20, 31, 14, 8, 17, 11, 14, 16, 16, 22, 23, 17, 26, 24, 20, 19,~
## $ ACE.2
           <dbl> 11, 12, 4, 1, 9, 25, 7, 15, 16, 4, 16, 4, 12, 7, 20, 2, 7, 7, ~
## $ DBF.2
           <dbl> 2, 3, 0, 4, 3, 3, 8, 2, 2, 2, 0, 12, 6, 1, 6, 3, 0, 2, 13, 3, ~
## $ WNR.2
           <dbl> 38, 57, 24, 16, 40, 53, 33, 40, 41, 22, 52, 17, 60, 23, 55, 40~
## $ UFE.2
           <dbl> 16, 32, 13, 27, 26, 30, 28, 26, 19, 15, 21, 44, 27, 34, 36, 10~
## $ BPC.2
           <dbl> 10, 15, 1, 0, 21, 12, 9, 10, 6, 6, 16, 1, 12, 2, 8, 1, 8, 8, 1~
## $ BPW.2
           <dbl> 5, 2, 0, 0, 3, 4, 2, 2, 4, 0, 5, 1, 6, 1, 4, 0, 6, 5, 3, 8, 5,~
## $ NPA.2
           <dbl> 23, 46, 19, 22, 44, 33, 11, 38, 11, 23, 50, 21, 61, 27, 26, 36~
## $ NPW.2
           <dbl> 17, 39, 12, 13, 30, 26, 10, 27, 8, 15, 32, 14, 44, 14, 17, 26,~
## $ TPW.2
           ## $ ST1.2
           <dbl> 6, 6, 2, 2, 6, 6, 3, 6, 6, 6, 7, 4, 6, 7, 7, 6, 6, 6, 3, 6, 6,~
## $ ST2.2
           <dbl> 6, 6, 4, 2, 7, 6, 4, 6, 6, 4, 6, 2, 6, 1, 6, 4, 6, 6, 6, 7, 6,~
           <dbl> 6, 7, 3, 4, 7, 7, 6, 7, 6, 2, 6, 3, 6, 4, 7, 3, 6, 6, 6, 6, 6, 6
## $ ST3.2
## $ ST4.2
           <dbl> NA, 7, NA, NA, NA, NA, 3, NA, NA, NA, 6, NA, 6, 3, NA, NA, NA,~
## $ ST5.2
```

9. Concaténer les tables en ajoutant une variable permettant d'identifier le tournoi. On pourra utiliser bind_rows() avec l'option .id.

10. Afficher les matchs de Federer pour chaque tournoi.

```
# Aucun match de Federer à Wimbledon ?
tbl %>%
filter(Player1 == "Roger Federer" | Player2 == "Roger Federer") %>%
select(Tournoi, Player1, Player2)
```

```
## # A tibble: 5 x 3
##
     Tournoi
                                       Player2
                  Player1
     <chr>
                  <chr>
                                       <chr>
## 1 RolandGarros Pablo Carreno-Busta Roger Federer
## 2 RolandGarros Somdev Devvarman
                                       Roger Federer
## 3 RolandGarros Julien Benneteau
                                       Roger Federer
## 4 RolandGarros Gilles Simon
                                       Roger Federer
## 5 RolandGarros Jo-Wilfried Tsonga Roger Federer
```

```
# Il faut faire attention ...
tbl %>%
  filter(grepl("Federer", Player1) | grepl("Federer", Player2)) %>%
  select(Tournoi, Player1, Player2)
## # A tibble: 7 x 3
```

```
## # A tibble: 7 x 3
##
    Tournoi
                 Player1
                                      Player2
##
     <chr>
                  <chr>>
                                      <chr>
## 1 RolandGarros Pablo Carreno-Busta Roger Federer
## 2 RolandGarros Somdev Devvarman
                                      Roger Federer
## 3 RolandGarros Julien Benneteau
                                      Roger Federer
## 4 RolandGarros Gilles Simon
                                      Roger Federer
## 5 RolandGarros Jo-Wilfried Tsonga Roger Federer
## 6 Wimbledon
                  V.Hanescu
                                      R.Federer
## 7 Wimbledon
                  S.Stakhovsky
                                      R.Federer
```

11. Comparer les nombres d'aces par matchs à chaque tour pour les tournois de Roland Garros et Wimbledon.

```
## # A tibble: 2 x 8
                  '1'
                         '2'
                            '3'
                                  44
                                          '5'
##
    Tournoi
                 <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <
## 1 RolandGarros 13.5 13.2 12.6 9.12
                                         7
                                              10
                  21.1 23.9 24
## 2 Wimbledon
                                  24.4
                                         26.5 27.5
                                                      13
```

Expressions régulières

À l'aide de la fonction str_extract() et d'une expression régulière, extraire la partie d'une chaîne de caractères située entre deux parenthèses. Par exemple, si la chaîne de caractères est J'aime (beaucoup) R, il faudra obtenir beaucoup.

```
s <- "J'aime (beaucoup) R"
str_extract(s, "(?<=\\().*(?=\\())")

## [1] "beaucoup"

# (?<=\\() : la recherche commence lorsque le curseur se trouve juste après '('
# .* : une chaîne de longueur 0 ou plus
# (?=\\)) : le curseur se trouve juste avant ')'</pre>
```